

20251110-维信业务介绍

智能客服复旦同步

话术推荐

1. 生成类方案：

1.1 策略进展：

策略定义：

策略1: 礼貌问候： 使用友好、专业的语言向客户致以问候，营造温馨的沟通氛围。

策略2: 确认身份： 通过询问客户的基本信息，确保服务的准确性和安全性。

策略3: 重述或转述： 对客户的问题进行重新表述，确保理解准确。

策略4: 细化问题： 通过详细提问确保全面和准确地理解客户需求。

策略5: 情感管理： 表达对客户感受的理解与关怀，帮助缓解不良情绪。

策略6: 提供建议： 根据客户的问题，提出专业的建议或行动步骤。

策略7: 信息传达： 清晰地说明流程或步骤，帮助客户理解解决方案的依据。

策略8: 解决实施： 实施商定的解决方案，确保所有步骤按计划进行，并向客户确认解决办法的进展情况。

策略9: 反馈请求： 在问题处理完毕后，征求客户的反馈，以了解他们的满意度和潜在的改进空间。

策略10: 关系延续： 引导客户关注未来服务或产品更新，确保他们了解如何在未来继续获得支持和服务，这也是进一步互动的桥梁。

策略11: 感谢与告别： 以积极的态度结束对话，确保客户感到被重视，并为下次互动打下良好基础。

策略12: 主动预见： 基于客户画像、历史交互数据（如频繁查看还款记录、曾咨询过分期），预判潜在需求，前置推送解决方案或关键信息（如“看到您常查还款计划，已为您推送下月还款明细”），减少客户提问成本、提升自助效率。

策略13: 跳出机制： 明确机器人服务切换至人工的触发条件（如客户情绪失控说“投诉”、问题涉及“账户冻结”等超机器人能力范围），并规范转人工衔接流程（如同步历史对话记录给人工坐席），避免无效交互、降低客户不满。

策略14: 其它： 不属于上述13种策略的情况

策略占比测试结果：

- 标注对话数量: 100条
- 总标注轮次: 465轮（平均每个对话约4.65轮客服回复）

策略编号	策略名称	数量	占比
策略7	信息传达	112	24.09%
策略4	细化问题	72	15.48%
策略8	解决实施	71	15.27%
策略2	确认身份	67	14.41%
策略5	情感管理	44	9.46%
策略1	礼貌问候	29	6.24%
策略6	提供建议	26	5.59%
策略11	感谢与告别	23	4.95%
策略9	反馈请求	14	3.01%
策略3	重述或转述	3	0.65%
策略10	关系延续	3	0.65%
策略14	其它	1	0.22%
策略12	主动预见	0	0.00%
策略13	跳出机制	0	0.00%

策略有效性验证：

策略标注：

- 标注对话数量: 434条
- 总标注轮次: 2014轮

排名	策略	数量	占比
1	信息传达	659	33.15%
2	解决实施	313	15.74%
3	细化问题	268	13.48%
4	确认身份	178	8.95%
5	情感管理	171	8.60%
6	关系延续	137	6.89%
7	提供建议	119	5.99%
8	反馈请求	59	2.97%
9	礼貌问候	55	2.77%
10	感谢告别	19	0.96%
11	重述转述	8	0.40%
12	其它	2	0.10%

评测集：strategy_evaluation_data_34.json

- 原模型： /data/model/Qwen2.5-7B-Instruct-repair-sft
- 微调后模型： /data/model/Qwen2.5-7B-Instruct-repair-sft-strategy

微调数据集：strategy_training_data_400.json

表格1: 整体性能对比分析

指标	模型1 (repair-sft)	模型2 (repair-sft-strategy)	变化
整体准确率	11.39%	20.25%	+8.86% 
正确预测数	18/158	32/158	+14个 
总样本数	158	158	=
生成成功率	100.00%	100.00%	=
评测耗时(秒)	34.51	54.35	+19.84s 
处理速度(样本/秒)	4.58	2.91	-1.67 
完全无法识别策略数	4	4	0

表格2: 各策略性能对比分析

策略	样本数	Qwen2.5-7B-Instruct-repair-sft			Qwen2.5-7B-Instruct-repair-sft-strategy		
		Precision	Recall	F1	Precision	Recall	F1
信息传达	55	25.00%	2.70%	4.88%	39.13%	16.36%	23.08%
细化问题	21	42.86%	23.08%	30.00%	13.64%	14.29%	13.95%
解决实施	21	0.00%	0.00%	0.00%	55.56%	23.81%	33.33%
情感管理	16	29.17%	70.00%	41.18%	8.70%	12.50%	10.26%
关系延续	15	33.33%	11.11%	16.67%	19.61%	66.67%	30.30%
确认身份	15	14.29%	62.50%	23.26%	18.75%	20.00%	19.35%
提供建议	9	12.50%	16.67%	14.29%	0.00%	0.00%	0.00%
礼貌问候	3	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
反馈请求	2	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
重述或转述	1	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
感谢与告别	0	-	-	-	-	-	-
其它	0	-	-	-	-	-	-

1.2 规则：

规则	类型	详解	目的
轮数3-30	筛选	一问一答为一轮对话，对话轮数必须在3到30轮之间	过滤极端长度
长度≤500	筛选	单句话不能超过500个字符	避免超长内容
有效比例≥0.6	筛选	客户的有效发言（超过2个字的实质性内容）必须占客户总发言的60%以上	确保客户参与
轮数平衡	筛选	客服的发言轮数不能超过客户的3倍，避免出现客服"自说自话"或客户几乎不参与的单向对话，这种对话不符合双向交互的本质	避免单方主导
删除重复	清洗	删除连续出现的完全相同的话语（如客户连续说3次"你好"），保留一次即可	去除冗余
删除JSON	清洗	删除系统自动发送的JSON格式消息（如系统：{"formModal":1,...}）	去除结构化噪音
删除HTML	清洗	删除所有HTML标签及其包裹的内容（如 内容 或 ）	去除标记语言
数值屏蔽	清洗	将日期（“截止到2025-11-01”），贷款数额（“贷款5123元”）转换为【日期】，【数额】等掩码，包括电话、人名等	防止学习到实际数据

去掉空格	清洗	去掉不正常的断句	
去掉系统客服等话	清洗	去掉系统客服的回复与问答	

1.3 数据进展：

获取： 总数据（2025-10-01_2025-10-06）1w8千条

清洗： 已根据规则清洗数据，数据清洗详细说明 [data_processing_principle.md](#)

1.4 核心指标对比

指标对比总结

指标	关注点	适用场景	分数范围
ROUGE-1	单词覆盖率	检查关键词是否出现	0-100
ROUGE-2	短语准确性	检查常用表达是否正确	0-100
ROUGE-L	整体连贯性	检查句子结构是否相似	0-100
BLEU-4	流畅度 + 精确度	检查生成质量（偏严格）	0-100

整体表现

指标	关注点	适用场景	基础模型	第一轮微调
模型	-	-	Qwen2.5-7B (原始)	Qwen-sft-kf
ROUGE-1 ↑	单词覆盖率	检查关键词是否出现	13.22	19.2
ROUGE-2 ↑	短语准确性	检查常用表达是否正确	1.57	6.26
ROUGE-L ↑	整体连贯性	检查句子结构是否相似	8.21	17.01
BLEU-4 ↑	流畅度 + 精确度	检查生成质量（偏严格）	1.55	5.55
样本数			109*	105
成功率			100%	100%

核心成果总结

 第一轮微调效果（5960条多轮对话训练）

-  ROUGE-1提升 45%（13.22 → 19.20）
-  ROUGE-2提升 296%（1.58 → 6.26）
-  BLEU-4提升 258%（1.55 → 5.55）

-  场景适配成功：通用助手 → 金融客服专家

2 第二轮微调效果（107标准话术 + 1788条防遗忘数据）

-  ROUGE-1提升 61% (19.20 → 30.98)
-  ROUGE-2提升 163% (6.26 → 16.45)
-  BLEU-4提升 183% (5.55 → 15.69)
-  话术规范化突破：自由对话 → 标准化表达

3 整体提升（基础模型 → 二轮微调后）

-  ROUGE-1提升 13.22 → 30.98
-  ROUGE-2提升 1.58 → 16.45
-  ROUGE-L提升 8.22 → 26.87
-  BLEU-4提升 1.55 → 15.69

关键发现

- a. 渐进式提升明显：每一轮微调都带来显著效果，未出现性能退化
- b. 话术标准化成功：第二轮BLEU-4翻倍提升，证明模型学会了标准表达
- c. 防遗忘有效：30%重放策略保持了对话能力，同时注入新知识

实例：

10.30 (<http://10.10.43.216:7862/>)

🤖 智能客服对话系统（含人工评分）

🗨️ 对话历史



您好亲亲，请问有什么可以帮您？

你好



用户输入

什么是赋强公证

发送

清空对话

⚙️ 生成参数配置

☰ 示例问题

我想提前清贷

我要投诉

为什么突然没有额度了

一天打我好多电话

你们平台安全吗？

怎么注销账号

什么是赋强公证

我要延期还款

👤 人工评分

✅ 已生成回复 (Session: 20251030160303_a158, ID: 0) | 模式: generate_with_system

请为最后一条回复打分：

评分 (1=很差, 5=很好)

3



根据回复的专业性、准确性、友好度打分

1



5

评价备注

选项：评价备注（如有问题可说明）...

提交评分

刷新统计

📊 暂无统计数据

🔄 微调前后对话效果对比


业务场景
逾期催收

对话轮数
6轮


整体提升
+12.3%

ROUGE-L
13.7% → 26.0%

🤖 微调前 Base



🚀 微调后 Fine-tuned



详细对比数据

轮次	微调前 ROUGE-L	微调后 ROUGE-L	提升幅度
第1轮	38.7%	61.5%	↑ +22.8%
第2轮	2.6%	21.6%	↑ +19.0%
第3轮	33.3%	37.5%	↑ +4.2%
第4轮	0.7%	19.4%	↑ +18.7%
第5轮	0.0%	6.2%	↑ +6.2%
第6轮	7.0%	10.0%	↑ +3.0%

💡 核心改进点

🏆 第1轮对话 - 提升 22.8%

👤 用户: 您好

🗨️ 微调前

您好! 很高兴为您服务。有什么问题或需要帮助的吗?

🗨️ 微调后

您好 请问有什么可以帮您的呢?

🏆 第2轮对话 - 提升 19.0%

👤 用户: 我想查询一下就是有没有贷后人员给我打过电话

🗨️ 微调前

要查询是否有贷后管理人员联系过您, 您可以直接联系您的贷款机构或平台进行询问。通常, 贷款机构会提供客服热线或者在线客服渠道供您咨询相关问题...

🗨️ 微调后

亲亲 您不要着急 您的问题我了解了, 辛苦您提供一下相关信息, 帮您处理一下
亲亲 稍等一会 查询中

🏆 第4轮对话 - 提升 18.7%

👤 用户: 有滴, 就是我最近接到了一个电话, 说是咱这边做了立案公示, 找了诉前调解员联系我。然后就有一个人加我说要我跟他签什么协议, 但是我觉得像骗子, 我就跟咱这边反馈一下, 看是不是咱这边的合作方, 能查到嘛?

🗨️ 微调前

接到这样的电话确实需要谨慎对待。通常情况下, 正规的司法程序不会通过这种方式直接与当事人联系要求签订协议。如果你对来电者的身份和意图感到怀疑, 可以采取以下几个步骤...

🗨️ 微调后

亲亲 具体是否是我司发送的短信, 我帮您反馈下, 帮您核实下亲
您方便提供下短信截图吗亲

1.5 人工评测

对话窗口

对话历史

为什么突然没有额度了



A: 您好, 您的额度是由系统自动审核的, 实时更新, 以您的APP端显示为准。目前申请人数较多, 我也很能理解您的心情, 很抱歉人工无法干预, 希望您能谅解, 建议您过段时间再尝试申请, 后续如有额度的时候可以及时提现;

我这边怎么没有额度了, 是不是你们平台出了问题



A: 您好, 您的额度是由系统自动审核的, 实时更新, 以您的APP端显示为准。目前申请人数较多, 我也很能理解您的心情, 很抱歉人工无法干预, 希望您能谅解, 建议您过段时间再尝试申请, 后续如有额度的时候可以及时提现;

用户输入

发送

请输入您的问题 (模拟客户) ...

清空对话

示例问题

我想提前清贷

我要投诉

为什么突然没有额度了

一天打我好多电话

你们平台安全吗?

反馈案例:

智能客服对话系统 (含人工评分)

对话历史

您好, 请问有什么可以帮您的呢?

开头语不规范

我要清贷

您填写一下个人信息, 我帮您查询

核身不规范

刘颜奎

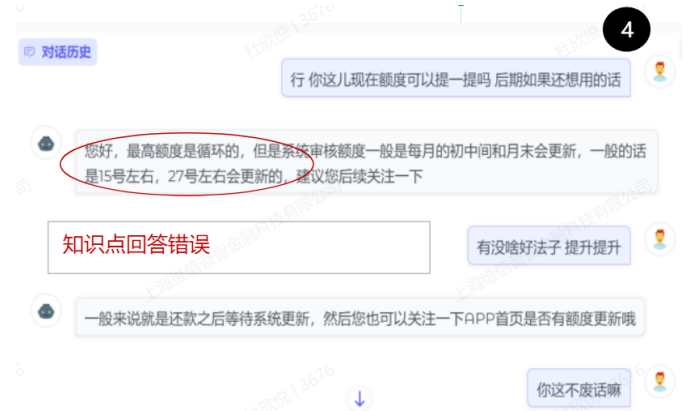
对话历史

请问您是什么原因需要结清的呢, 我好帮助您去结清

有钱了, 提前还了, 你们这儿利息太高了, 黑心

您好, 理解您的意思, 可能您现在没有资金的需求, 但还是建议您先进行按期还款。其实我们很多客户都和您差不多, 并不是缺钱才申请, 而是想在一些大平台上做个信用积累, 所以还是建议您考虑按期还款哦, 如果您在使用期间有任何问题的话, 也可以在服务时间和我们联系哦, 我这边全力帮您解决问题。

不要了 我就要清贷 速度点



2. 微调生成固定话术：

缺点：重新设计微调方案

优点：生成速度快

3. 结合RAG方案

(扩写) + 生成+RAG (已实现)

目前有固定话术推荐文档，通过对于客户对话进行总结+分类结合RAG召回TOP1固定话术。-- 72% (测试)

合规质检

1、示例数据：

关键因素：1.服务耐心 2.一次性解决客服问题 3.执行/操作规范 4.服务敏感

非关键项：1.欢迎问候语 2.语音语调 3.服务专业和用语规范 4.适当的表示认同、理解、关心和感谢

5.主动完整的提醒/专业的业务知识 6.明确客户来电意图 7.合理利用资源，保证电话效率

8.电话总结/短信 9.感谢客户致电

检查日期	姓名	员工属性	在线/电话	会话ID	会话日期	问题类
2025/1/2	陈洪星	新员工	在线	743223627025776	2025/1/1	还款柜
2025/1/2	陈菊	正式员工	在线	743067961164554	2025/1/1	催收柜
2025/1/2	丁豪冲	正式员工	在线	742599590821150	2025/1/1	还款柜

2、评分计算口径

- 监听量：当日/当月监听的通话或聊天会话的量。
 - 关键分 = 1－命中关键项的数量/监听量×100%
(注：命中关键项的数量 = 1通录音有关键问题，即计1次) 。
 - 非关键分 = 1－命中非关键项的数量/（监听量×9）×100%
(注：命中非关键项的数量 = 非关键项错误总次数；9为非关键项总数) 。
- 举例：监听量4通，命中1个关键项，2个非关键项，则关键通过率：1-1/4*100%=75%；非关通过率：1-2/(4*9)*100%=94.5%。

3、判定上线标准

- 优秀：
 - 关键分 = 100% ， 非关键分 =100%。
 - 表现特征：无关键项、无非关键违规，有主动服务，被客户表扬，话术优秀。
- 合格：
 - 关键分 ≥ 96% ， 非关键分 ≥ 98%。
 - 表现特征：基本无关键项违规，非关键项错误极少，服务流畅专业。
- 不合格：
 - 关键分 < 96%， 非关键分 < 98%。
 - 表现特征：频繁违反关键项（如流程错误、服务推诿），非关键项错误多，服务体验差。

客服小结

	A	B	C	D	E	F	G	H	I
1	测试集	数据量	模型	精度	是否微调	一级准确率	二级准确率	三级准确率	训练集
2	小结0905.xlsx	100	qwen3-32b	8	否		75%	52%	
3		100	qwen2.5-7b-instruct	16	是	91%	75%	75%	电话小结名称数据.xlsx 09.08_小结 - 第二次返回(3).xlsx
4		100	qwen2.5-7b-instruct	16	是	89%	74%	34%	电话小结名称数据.xlsx
5		100	Longformer-Chinese	fp32	是	47%	47%	47%	电话小结名称数据.xlsx
6		100	RoBERTa-WWM-La	fp32	是	43%	43%	43%	电话小结名称数据.xlsx
7	09.08_小结 - 第二次返回.xlsx	249	qwen3-32b	8	否		73.00%	61%	
8		245	qwen2.5-7b-instruct	16	是	91.84%	78.37%	71.02%	电话小结名称数据.xlsx 小结0905.xlsx
9		245	qwen2.5-7b-instruct	16	是	91%	78%	43%	电话小结名称数据.xlsx
10		245	Longformer-Chinese	fp32	是	41%	41%	41%	电话小结名称数据.xlsx

一、本周模型测试结果

1.1 已上线模型表现

- 模型: Qwen3-32B-8bit (未微调)
- 测试集: 小结0905.xlsx (100条数据)
- 准确率: 二级75% | 三级52%

1.2 微调实验对比

Qwen2.5-7B-instruct 模型表现

训练数据配置	三级准确率	测试结果说明
仅原始数据（电话小结名称数据.xlsx）	34%	在混合测试集上表现差
原始数据 + 200条人工标注数据	75%	准确率提升41个百分点
仅原始数据训练，原始测试集测试	78%	同源数据表现良好
混合数据训练，原始测试集测试	40%	跨数据源泛化能力差

模型结果对比（小结0905测试集-100条数据）

模型	一级准确率	二级准确率	三级准确率	备注
Qwen2.5-7B (原始数据+人工标注)	91%	75%	75%	最佳表现
Qwen2.5-7B (仅原始数据)	89%	74%	34%	三级分类差
Longformer-Chinese	47%	47%	47%	无法利用提示
Qwen3-32B-8bit	-	75%	52%	基准分数

核心发现:

- a. 原始数据与人工标注数据标准不一致，导致模型泛化能力受限
- b. Longformer等BERT架构模型表现显著差于Qwen系列（准确率相差30-50个百分点）
- c. 大语言模型（Qwen）在复杂分类任务上具有明显优势

二、坐席小结分类分布统计（共141类）

基于57,846条实际客服对话数据的分类分布：

排名	分类路径	数量	占比(%)	累计占比(%)
1	催收相关/协商还款/逾期	13,068	22.59	22.59
2	催收相关/要求停催/客户来电停催本人	4,358	7.53	30.12
3	还款相关/存对公还款/存对公咨询	2,445	4.23	34.35
4	还款相关/提前清贷/提前清贷-资金充裕	2,134	3.69	38.04
5	还款相关/账单信息查询/未结清查询账单	1,976	3.42	41.46
6	还款相关/还款咨询/银行卡异常还款失败	1,966	3.4	44.86
7	营销活动/新活动咨询/优享卡	1,876	3.24	48.10
8	还款相关/还款咨询/余额不足还款失败	1,626	2.81	50.91
9	营销活动/会员退费/先享后付-月卡	1,458	2.52	53.43
10	还款相关/提前清贷/提前清贷卡控	1,415	2.45	55.88

2.1 一级分类分布

一级分类	占比估算	主要场景
催收相关	~38%	协商还款、停催要求、投诉催收
还款相关	~25%	还款咨询、提前清贷、账单查询
营销活动	~12%	会员退费、活动咨询
业务办理	~8%	账户注销、征信相关、结清证明
费用相关	~5%	退费要求、费用咨询
其他类别	~12%	产品信息、申请咨询等

2.2 数据分布特征

- a. 高度集中: 前10类占比55.88%，前20类占比75.05%
- b. 长尾分布: 共143个细分类别，后100类仅占不到10%
- c. 业务特点: 催收和还款相关占据主导地位（超60%）

三、分类预测建议

3.1 优先优化的高频分类（建议重点关注）

基于数据分布，建议优先确保以下高频分类的准确识别：

第一梯队（占比>3%，共6类，累计44.86%）

- 催收相关/协商还款/逾期（22.59%）

- 催收相关/要求停催/客户来电停催本人 (7.53%)
- 还款相关/存对公还款/存对公咨询 (4.23%)
- 还款相关/提前清贷/提前清贷-资金充裕 (3.69%)
- 还款相关/账单信息查询/未结清查询账单 (3.42%)
- 还款相关/还款咨询/银行卡异常还款失败 (3.40%)

第二梯队 (占比1.5-3%, 共16类, 累计30.19%)

- 重点关注营销活动类 (会员退费、活动咨询)
- 业务办理类 (账户注销、征信相关)
- 费用相关类 (退费要求)

3.2 模型优化策略

a. 分层训练策略

- 一级分类: 重点优化"催收相关"和"还款相关" (占63%)
- 二级分类: 针对高频子类别进行专项优化
- 三级分类: 优先保证前40类的准确率 (占91.36%)

b. 数据增强建议

- 为前20类各补充50-100条高质量标注数据
- 特别加强"催收相关/协商还款"的样本多样性
- 增加边界案例和易混淆类别的对比样本

c. 评估指标设计

- 加权准确率: 按实际分布权重计算
- 分层评估: 分别评估高频类 (前20)、中频类 (21-60)、低频类 (60+)
- 重点监控: 前10类的召回率和精确率

四、核心结论

- a. 数据质量是关键瓶颈: 原始数据与人工标注数据标准不一致, 导致模型性能上限受限
- b. 分类分布极不均衡: 前20类占75%, 需要针对性的不平衡学习策略
- c. 下一步计划:
 - 统一标注标准, 重新审核现有数据
 - 优先收集和标注高频类别的高质量数据
 - 采用分层训练策略, 确保高频类别的识别准确率
 - 区分在线和热线数据集

五、重点事项

1.客服所有业务场景List

2.重点业务场景（收益高、关注度高、当前难点、关注的业务指标）

- 话术推荐
- 合规质检

会议纪要

1. 生成和质检最后要交付两个模型，还是一个？

答：并不限制一个或两个模型，只要效果够好，达到实际业务落地需求即可

2. 文档是否可以共享？（包括那个开头语那个等文件）

答：正式签合同之后可以全部共享

3. 测评需要好好沟通，我们应该还是以论文中模型的评测为主

答：发论文采用什么评测方式我们不干预，但在我们的应用场景下需要把业务需求转化为对应的量化指标（例如提到的关键项通过率等，详细后续可沟通商量），并且人工评测是最重要的，直接关系到项目能否成功落地上线，由业务部和测试部共同参与

4. 合同里有个意图识别准确率，不知道在哪一类任务上

答：以实际落地的需求为准，没有那么关注合同中的详细指标

总结：关于合同中写到的一些指标包括问到的意图识别准确率，维信领导们的意思就是说其实公司不会特别关注合同上写的那些指标，因为其实都是很笼统的，公司还是会更关心实际落地的问题，就是能不能达到业务那边的要求。